Prácticas de Visión por Computador
Grupo 2

Trabajo 2:

Detección de puntos relevantes y Construcción de panoramas

Pablo Mesejo
Universidad de Granada
Departamento de Ciencias de la Computación e Inteligencia Artificial

UNIVERSIDAD
DE GRANADA

Índice

- Normas de entrega
- Breve repaso teórico
- Presentación de la práctica

Índice

- **Normas de entrega**
- Breve repaso teórico
- Presentación de la práctica

Normas de la Entrega de Prácticas

- Dos opciones:
  a) Se entrega memoria (PDF) y código (.py o .ipynb) → ZIP/RAR
  b) Se entrega solamente un fichero .ipynb integrando directamente el análisis y discusión

Normas de la Entrega de Prácticas

- Solo se entrega memoria y código fuente → no imágenes!
- Lectura de imágenes o cualquier fichero de entrada: “imagenes/nombre_fichero”
- Todos los resultados numéricos serán mostrados por pantalla. No escribir nada en el disco.
- La práctica deberá poder ser ejecutada de principio a fin sin necesidad de ninguna selección de opciones.
- Puntos de parada para mostrar imágenes, o datos por terminal.

Entrega

- Fecha límite: 18 de Noviembre
- Valoración:
  - hasta 12 ptos (9 + 3 bonus), si se realiza toda la práctica con código propio, sin usar funciones de OpenCV en tareas de Visión por Computador (no se incluyen aquí cuestiones de visualización, p.ej).
  - Hasta 11 ptos (8 + 3 bonus), si se emplean funciones de OpenCV
- Lugar de entrega: PRADO
- Como siempre, **se valorará mucho la memoria:** descripción de qué se ha hecho y cómo, justificación de las decisiones tomadas, discusión y análisis de los resultados obtenidos

Dudas

Enviad todas las dudas que tengáis a

pmesejo@go.ugr.es

Si vemos que no es posible resolver las dudas por email, o en clase, concertaríamos una reunión para hacer una tutoría

Índice

- Normas de entrega
- **Breve repaso teórico**
- Presentación de la práctica

Prácticas anteriores

- P0: introducción a OpenCV

- P1: procesado de imágenes

P2: detección de puntos de interés y creación de panoramas

Geometría (*geometry*)

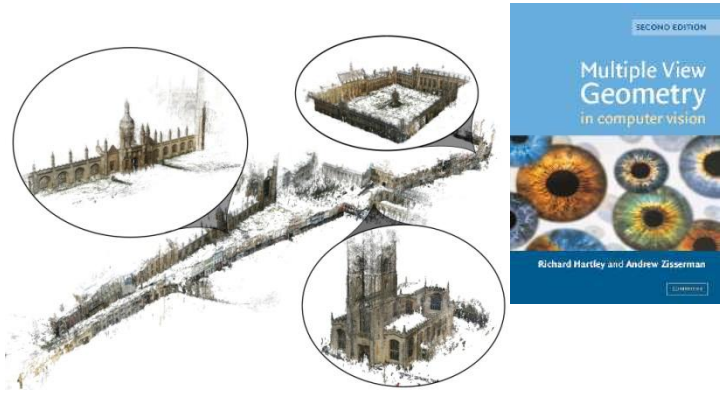

https://alexgkendall.com/computer_vision/have_we_forgotten_about_geometry_in_computer_vision/

Práctica 3

Aprendizaje (*learning*)

http://cs231n.stanford.edu/

Detección de puntos de interés

Feature = keypoint + descriptor

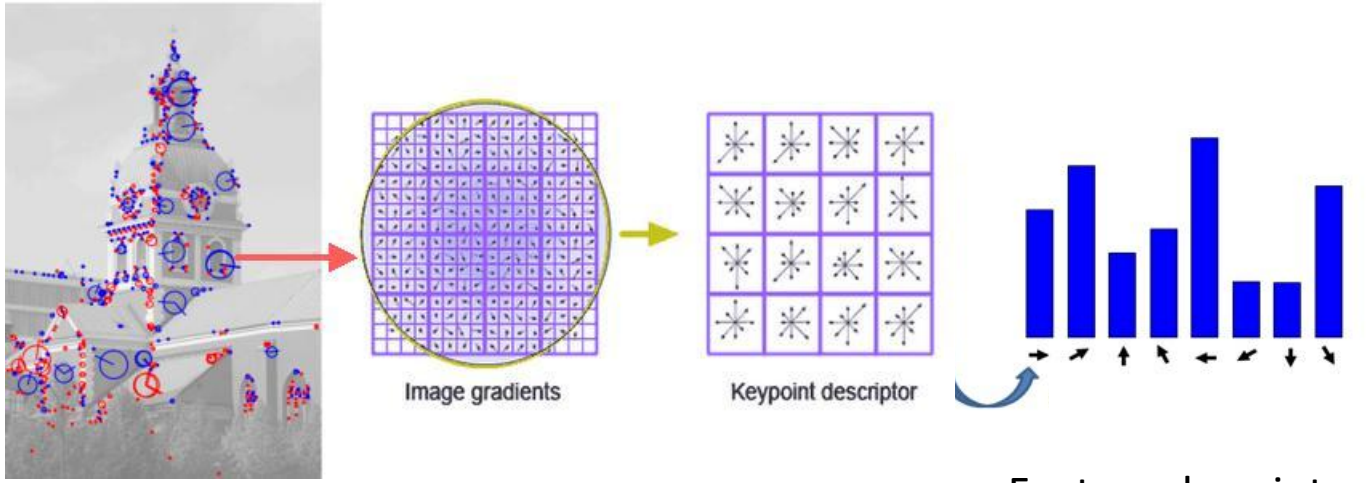

keypoints

Feature descriptor

https://gilscvblog.com/2013/08/18/a-short-introduction-to-descriptors/
https://www.codeproject.com/Articles/619039/Bag-of-Features-Descriptor-on-SIFT-Features-with-O

Detección de puntos de interés

1) Detection: Identify the interest points

2) Description:Extract vector feature descriptor surrounding each interest point.

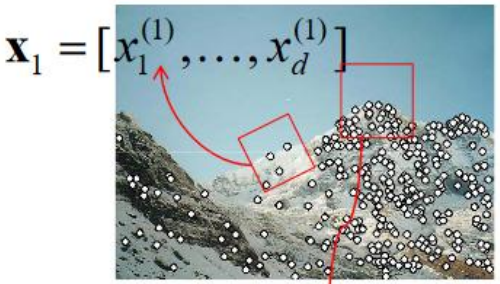

3) Matching: Determine correspondence between descriptors in two views

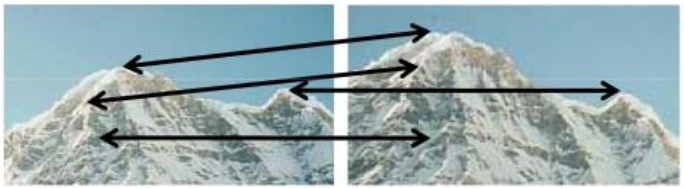

https://www.cs.utexas.edu/~grauman/courses/trento2011/slides/Monday_LocalFeatures.pdf

Detección de puntos de interés

Vectores describiendo cada punto/región

FEATURE DETECTION **FEATURE DESCRIPTION**

SIFT es a la vez un detector y un descriptor y, para la parte de detección de keypoints , utiliza la Diferencia de Gaussianas en imágenes reescaladas

Edge detection (Canny, Sobel,…)
Corner detection (Harris, FAST,…)
Blob detection (LoG, DoG,…)

SIFT, SURF, HOG, KAZE,…
GLCM, LBP,…

Más información sobre *Feature Detection* con *OpenCV*:
https://docs.opencv.org/4.4.0/db/d27/tutorial_py_table_of_contents_feature2d.html

Detección y descripción de puntos de interés

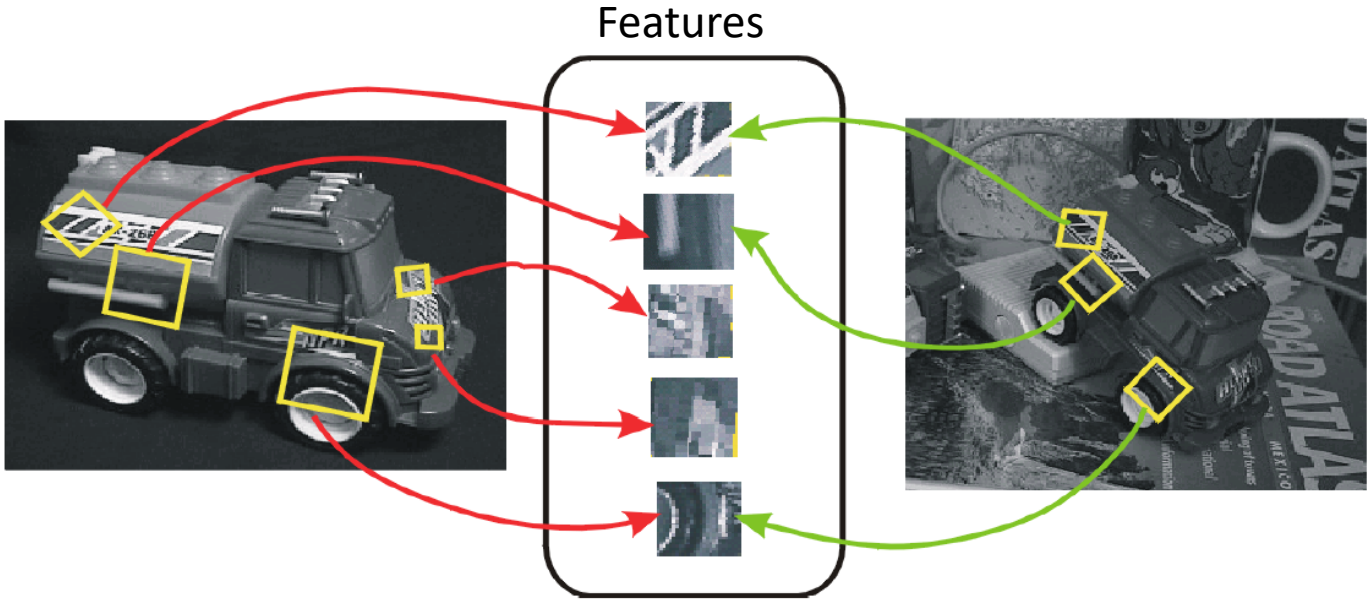

Detection is *covariant*:

features(transform(image)) = transform(features(image))

Description is *invariant*:

features(transform(image)) = features(image)

Importancia de la *scale invariance*

- Detector de Harris

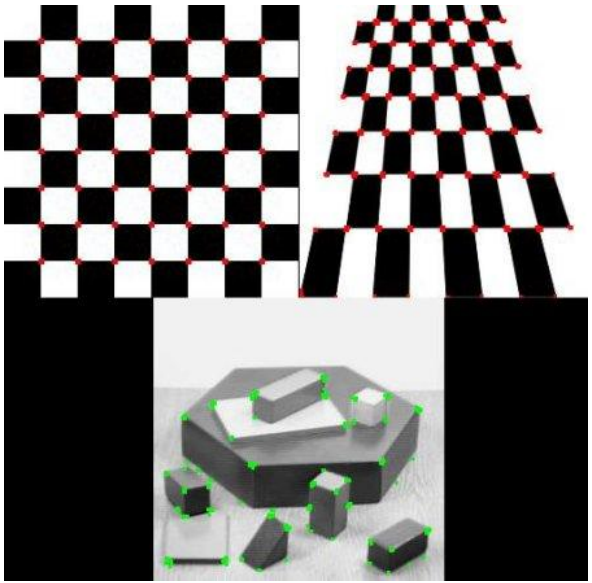

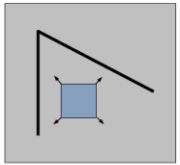

"flat" region:
no change in all directions

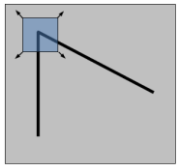

"corner":
significant change in all directions

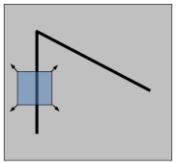

"edge":
no change along the edge direction

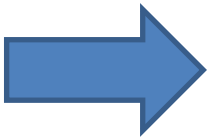

- Rotation invariance

- **Not invariant to *image scale*!**

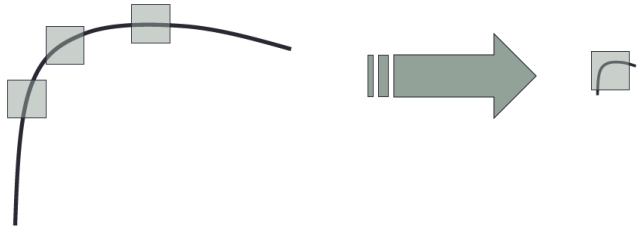

All points will be classified as edges

Corner !

SIFT (Scale Invariant Feature Transform)

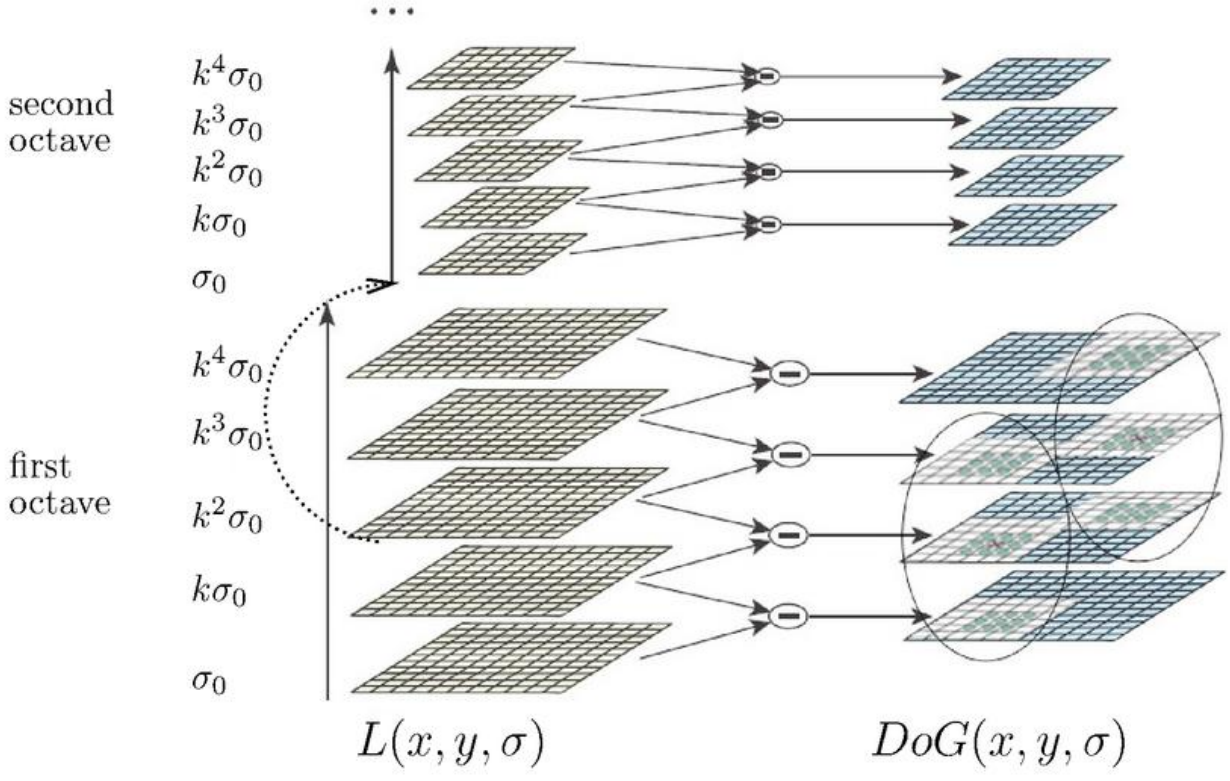

Invariante a:
- Traslación
- Rotación
- Escalado

Robusto a:
- Cambios de punto de vista
- Cambios de iluminación
- Ruido
- Cambios de contraste

Image extracted from Younes, L., Romaniuk, B., & Bittar, E. (2012). A comprehensive and comparative survey of the SIFT algorithm. In *International Conference on Computer Vision Theory and Applications* (Vol. 2, pp. 467-474)

David G. Lowe. "Distinctive image features from scale-invariant keypoints."*IJCV 60 (2), pp. 91-110, 2004*

SIFT (Scale Invariant Feature Transform)

1. We have an input image with asumed $\sigma = 0.5$ (acquisition)
2. To correctly compute Differences-of-Gaussian on the input image, an octave with index -1 is included:
   1. Input image is smoothed to an initial scale ($\sigma_{ini} = 0.8$) (Lowe)
   2. Sub-sampling by bilinear interpolation with step $\delta_0 = 0.5$: $\sigma_0 = \frac{\sigma_{ini}}{\delta_0} = 1.6$
3. Assuming 3 scales by each octave, $ns = 3$, apply iterative smoothing with $\sigma_s = \sigma_0 \times \sqrt{2^{\frac{2s}{ns}} - 2^{\frac{2(s-1)}{ns}}}, s = 1, .., ns + 2$
4. Subsampling the scale with $ns = 3$ step $\delta = 2$ we compute the initial scale of the next octave. Use function ceil() to round the sizes.
5. Repeat 3 and 4 for each new octave.

SIFT (Scale Invariant Feature Transform)

"Anatomy of the SIFT Method" (Ives Rey-Otero, Mauricio Delbracio)
Image Processing On Line, 2014 http://dx.doi.org/10.5201/ipol.2014.82

Distancia entre píxeles. δ=1 para la imagen en tamaño original

Aquí vemos 5 octavas y 3 escalas (ns=3) por octava

ns+2 DoG

Imagen original

Imagen inicial/base/semilla

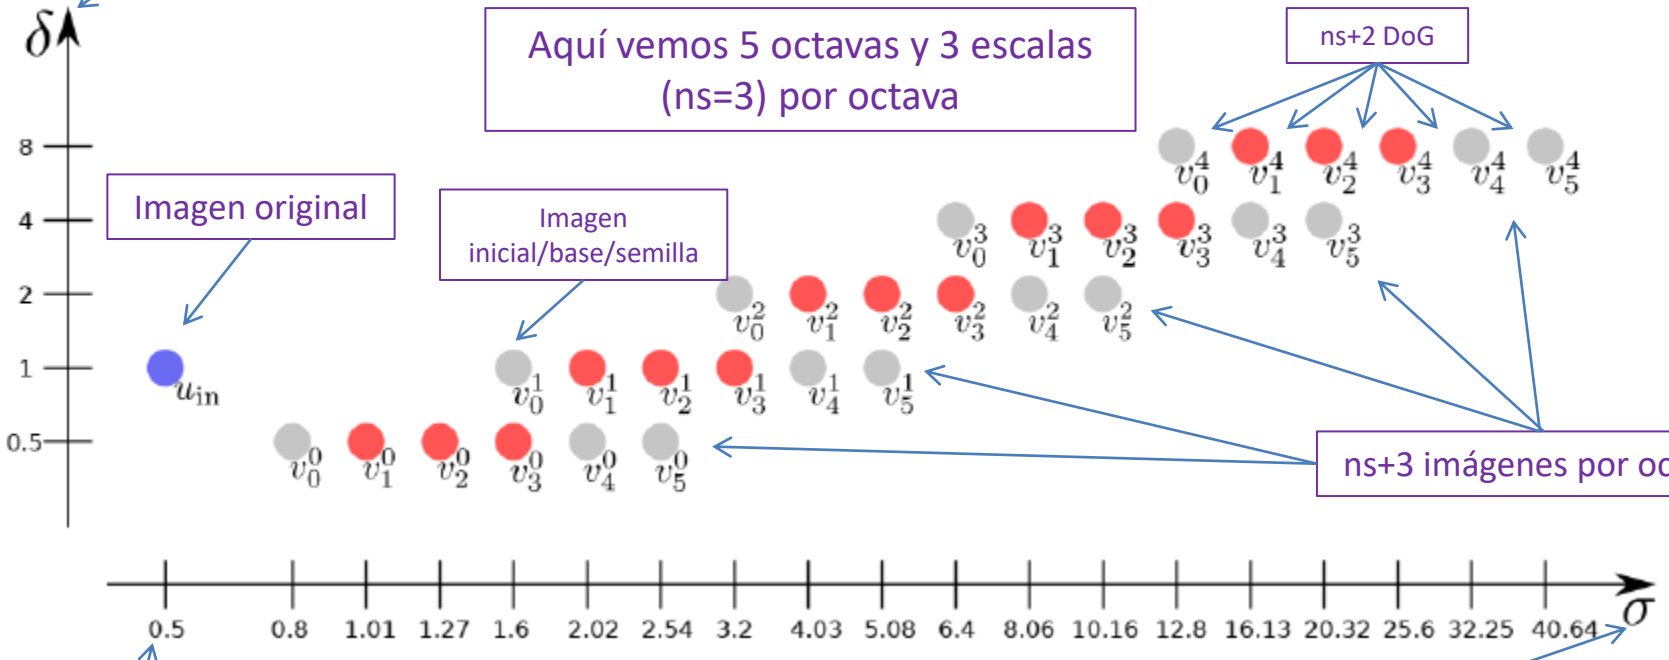

ns+3 imágenes por octava

σ de adquisición de la imagen

En cada octava, el sigma efectivo pasa de σ a 2σ

Nivel de suavizado real/absoluto
$\sigma_k = \sigma_0 \cdot 2^{k/ns}$

SIFT (Scale Invariant Feature Transform)

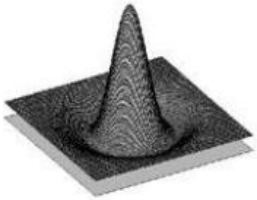

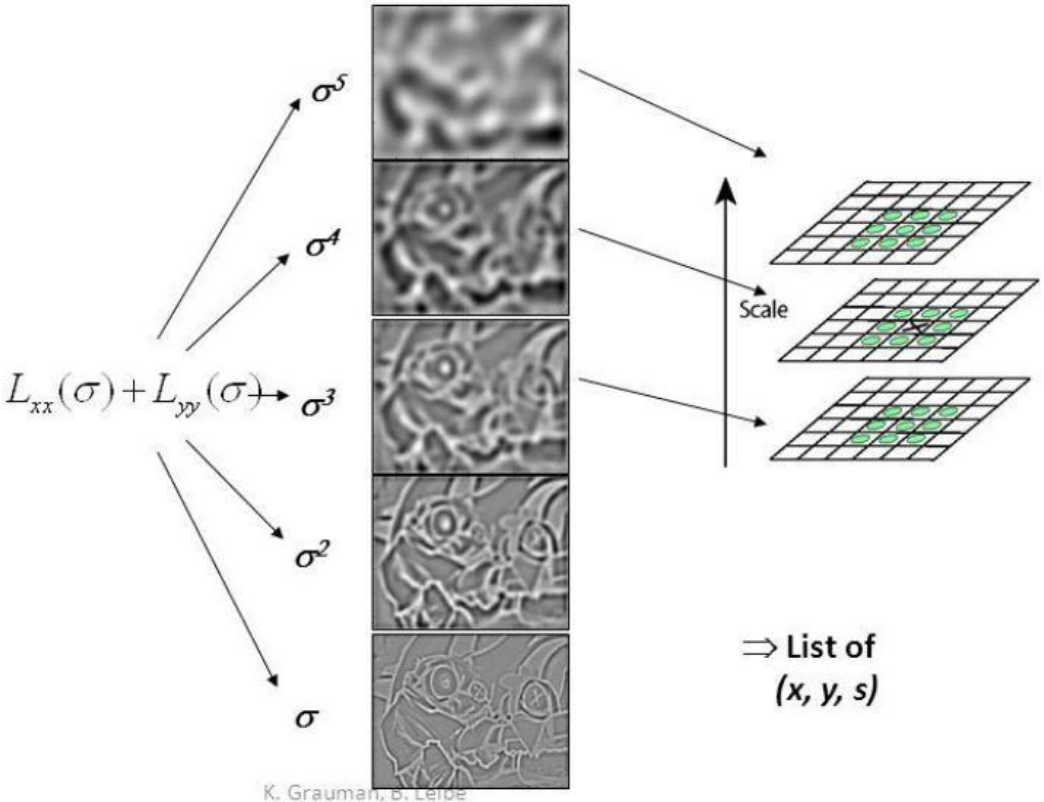

K. Grauman, B. Leibe

Seleccionar el píxel **X** si es el máximo/mínimo que sus 26 vecinos

Creación de Panoramas (*Image Stitching*)

- Proceso de combinar múltiples imágenes parcialmente solapadas para producir un panorama o imagen de alta resolución.

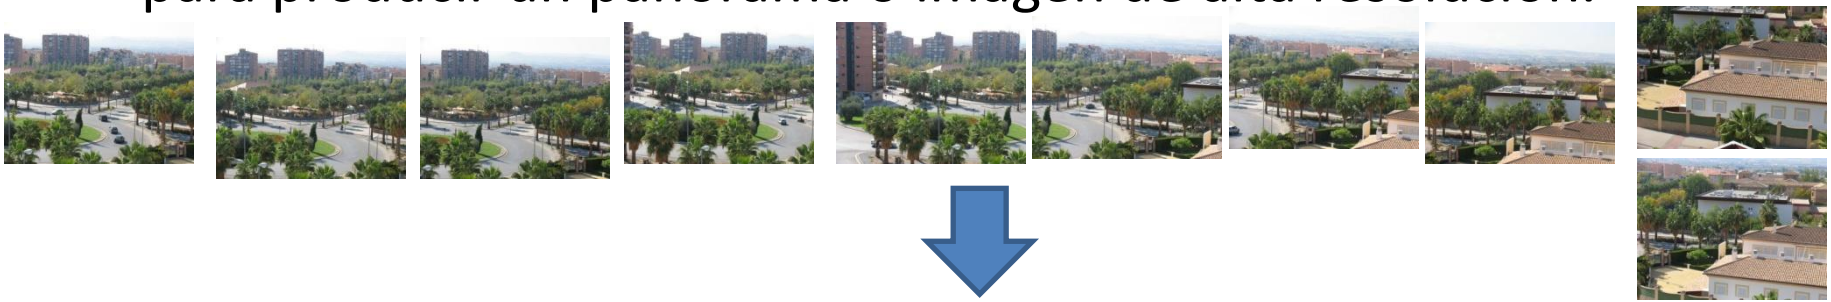

¿Cómo construimos un panorama?

- Necesitamos alinear imágenes

¿Cómo construimos un panorama?

- Detectamos puntos en ambas imágenes

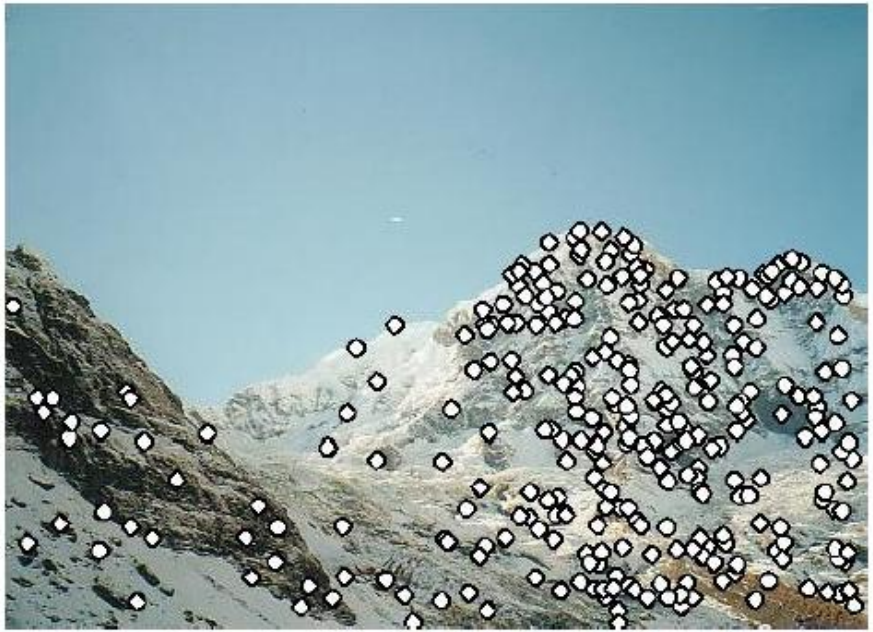

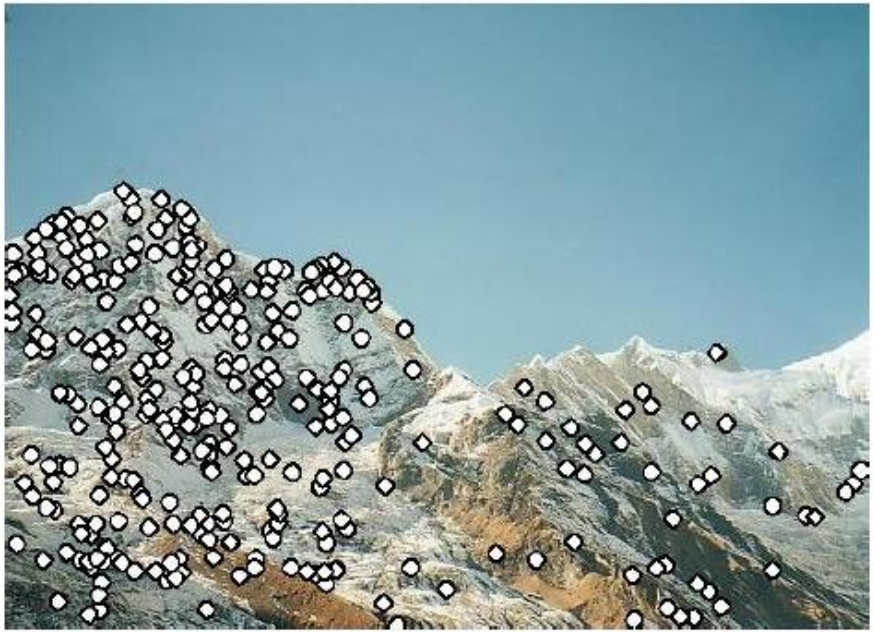

¿Cómo construimos un panorama?

- Encontramos pares correspondientes

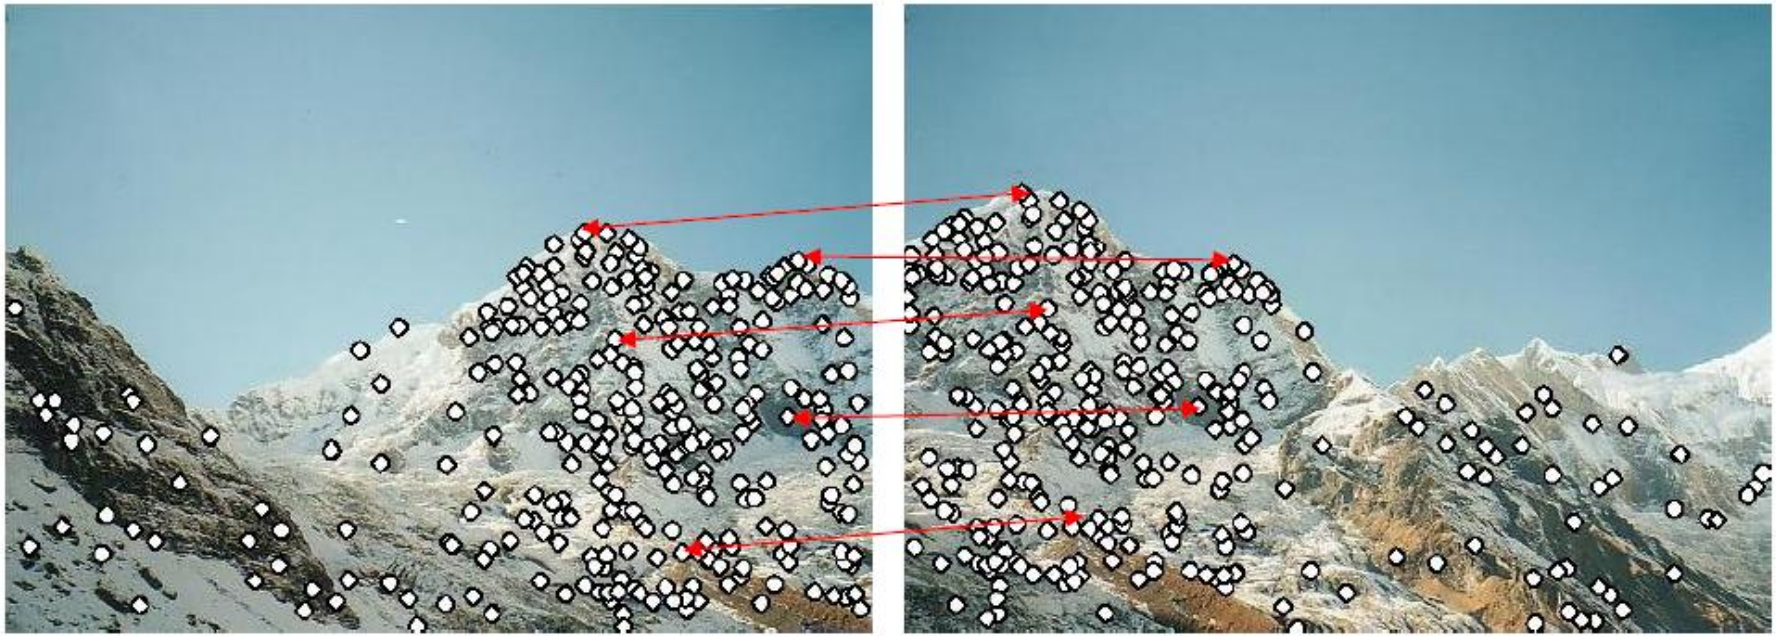

¿Cómo construimos un panorama?

- Usamos dichos pares para alinear las imágenes

Problema 1

- Detectar el mismo punto independientemente en ambas imágenes
  - Necesitamos un **detector** repetible/estable

no chance to match!

Problema 2

- Para cada punto, debemos ser capaces de encontrar su punto correspondiente en la otra imagen
  - Necesitamos un **descriptor** fiable y distintivo

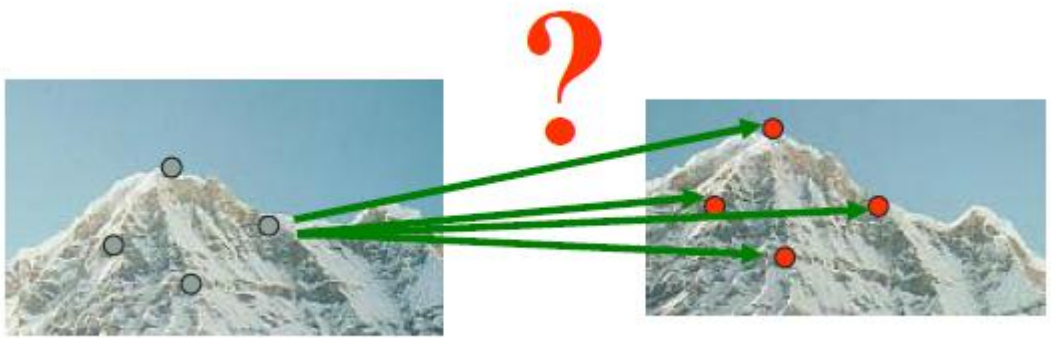

Construcción de Panoramas

- Aquí es donde entra en juego SIFT, como detector y descriptor
- Y la construcción de panoramas por medio de homografías

Homografías

- Cualesquiera dos imágenes de la misma superficie están relacionadas por una homografía.
- Una homografía es una transformación (matriz 3x3) que permite mapear (*map/warp*) puntos de una imagen en la otra.

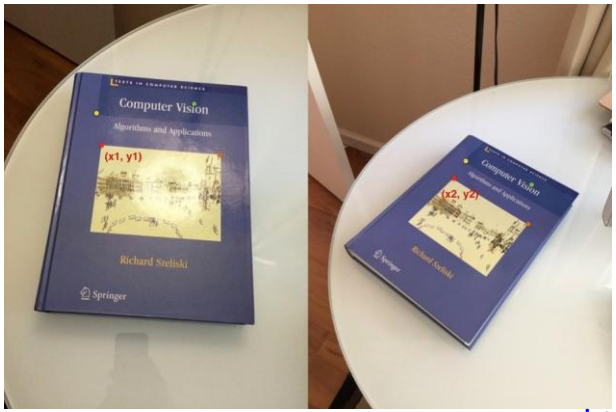

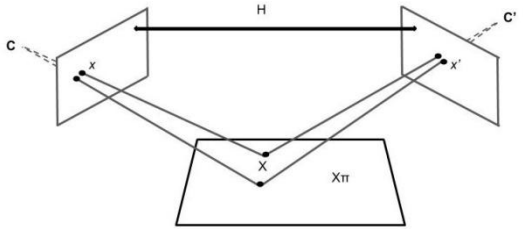

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = H \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix} = \begin{bmatrix} h_{00} & h_{01} & h_{02} \\ h_{10} & h_{11} & h_{12} \\ h_{20} & h_{21} & h_{22} \end{bmatrix} \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix}$$

https://www.learnopencv.com/homography-examples-using-opencv-python-c/

Índice

- Normas de entrega
- Breve repaso teórico
- **Presentación de la práctica**

Ejercicio 1: detección de puntos en una pirámide de Lowe (4 ptos)

Construir pirámide de Lowe de 4 octavas y 3 escalas para cada imagen de Yosemite.zip.


a) ¿Qué operación sobre la imagen original nos permite fijar un σ_0=1.6?
   - ¡Revisad la teoría! Punto 2 de "How to build it?"
   - NO aplicamos directamente ningún filtro sobre la imagen original (u_{in})!
   - Construir la imagen inicial/base del espacio de escalas

b) Implementar una función que calcule las imágenes de la primera octava de la forma más eficiente y reusable posible
   - ¡Kernels pequeños!
   - Función que proporciona todas las escalas de una octava, a la que se le pasa como entrada una imagen inicial, el número de escalas por octava, y σ_0

c) Construir todas las octavas, y mostrar las primeras 3 escalas de cada octava.

Ejercicio 1: detección de puntos en una pirámide de Lowe (4 ptos)

d) Calcular el espacio de escalas Laplaciano de la pirámide y extraer los 100 extremos locales con mayor respuesta.

e) Mostrar la imagen con los extremos locales.
   - Círculo de radio 6x sobre la escala de detección σ
   - Véase cv2.KeyPoint() y cv2.drawKeypoints()

f) BONUS: Si todo el ejercicio se realiza con código propio se obtendrá 1 pto extra.

Ejercicio 2: descriptores SIFT (1.5 ptos)

- Usar descriptores SIFT y calcular el emparejamiento/correspondencia entre las dos imágenes de Yosemite.

```
sift = cv2.SIFT_create()
kpts1, desc1 = sift.detectAndCompute(img1, None)
kpts2, desc2 = sift.detectAndCompute(img2, None)
```

https://docs.opencv.org/4.5.4/d7/d60/classcv_1_1SIFT.html

https://docs.opencv.org/master/da/df5/tutorial_py_sift_intro.html

Ejercicio 2: descriptores SIFT (1.5 ptos)

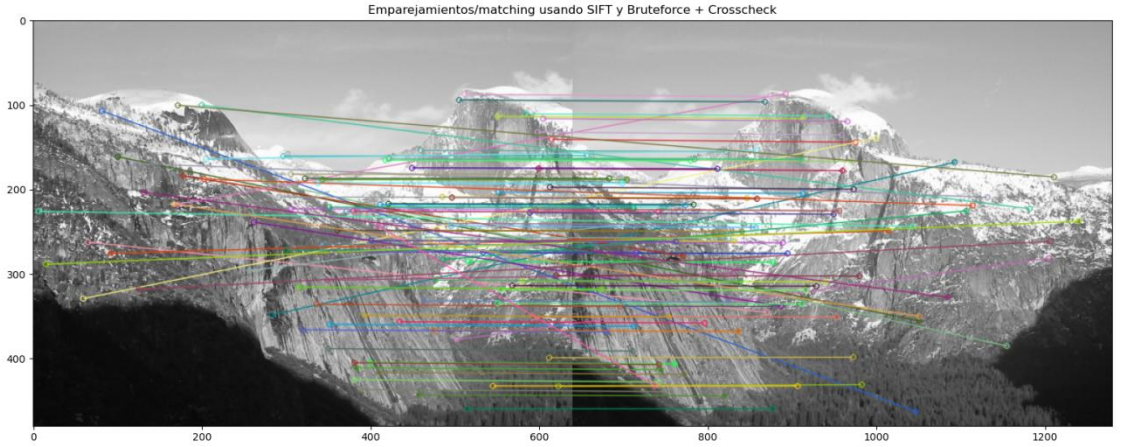

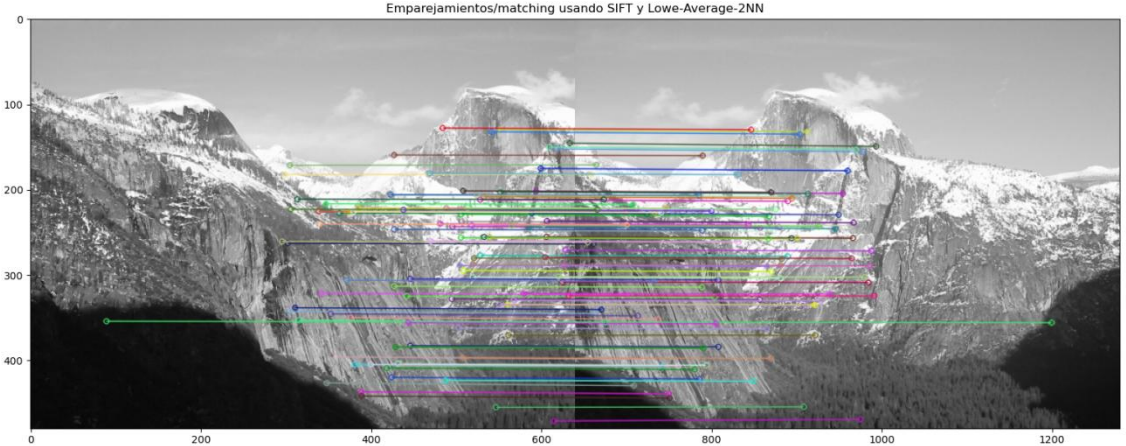

Ejercicio 3: construir panorama con 3 imágenes (2.5 ptos)

- Se trata de hacer lo mismo que en el anterior ejercicio, pero ahora, junto con el cálculo de las correspondencias, aplicamos la transformación correspondiente para alinearlas.

- Se trabaja con 3 imágenes de mosaico.rar

Ejercicio 3: construir panorama con 3 imágenes (2.5 ptos)

a) Extraer los KeyPoints SIFT y establecer un conjunto de puntos en correspondencias entre cada dos imágenes solapadas,

b) Estimar la homografía entre las imágenes a partir de dichas correspondencias → cv2.findHomography()

c) Componer y visualizar el mosaico obtenido → cv2.warpPerspective() con cv.BORDER_TRANSPARENT

Ejercicio 3: construir panorama con 3 imágenes (2.5 ptos)

H0: homografía de traslación al canvas

BONUS B1:

refinar extremos en espacio de escalas Laplaciano (1.5 ptos)

- Implementar el refinamiento de puntos extremos en el espacio de escalas Laplaciano. Aplicarlo a los puntos encontrados en el ejercicio 1, y mostrar que la implementación realmente mejora la estimación inicial.
  - Interpolar keypoint dentro del “cubo” en que ha sido detectado para moverlo a la mejor localización posible.
  - Revísese "3D-interpolation" de la teoría.

BONUS B2: construir mosaico completo (1.5 ptos)

- Igual que el ejercicio 3, pero empleando las 10 imágenes que están en mosaico.rar y, por tanto, reconstruyendo un panorama más amplio.

BONUS B2: construir mosaico completo (1.5 ptos)

- Importancia de seleccionar correctamente la imagen de referencia
  - Si la primera imagen en el canvas es la imagen de más a la derecha, al llegar al otro extremo la imagen estará muy deformada (fruto de la composición de múltiples homografías)

Referencias Útiles

- Interest Point Detector and Feature Descriptor Survey: https://core.ac.uk/download/pdf/81870989.pdf
- Image Matching: https://ai.stanford.edu/~syyeung/cvweb/tutorial2.html
- Local features: detection and description. https://www.cs.utexas.edu/~grauman/courses/trento2011/slides/Monday_LocalFeatures.pdf
- Documentación OpenCV relevante:
  - https://docs.opencv.org/4.5.4/d7/d60/classcv_1_1SIFT.html
  - https://docs.opencv.org/master/da/df5/tutorial_py_sift_intro.html
  - https://docs.opencv.org/4.4.0/db/d27/tutorial_py_table_of_contents_feature2d.html
  - https://docs.opencv.org/4.4.0/d9/dab/tutorial_homography.html
  - https://theailearner.com/tag/cv2-integral/
  - https://docs.opencv.org/master/d7/d1b/group__imgproc__misc.html

Prácticas de Visión por Computador
Grupo 2

Trabajo 2:

Detección de puntos relevantes y Construcción de panoramas

Pablo Mesejo
Universidad de Granada
Departamento de Ciencias de la Computación e Inteligencia Artificial

UNIVERSIDAD
DE GRANADA